


Machine Learning

Chapter06 선형분류 svm, logistic

양재원 연구원



- 선형 분류모델을 이해하고 사용 할 수 있다.
- 다양한 분류평가 지표를 이해 할 수 있다.

Linear Model (선형 모델)

- 다양한 선형 모델이 존재
- 입력 특성에 대한 선형 함수를 만들어 예측을 수행
- 분류와 회귀에 모두 사용 가능

Linear Model (선형 모델) 사용 이유

- 단순성 및 해석 용이성
 - 입출력 사이 관계가 선형식으로 표현되어 직관적 해석 가능
- 빠른 계산 속도, 효율성
 - 계산 비용 낮고, 학습 및 예측이 빠름
- 과적합 위험 낮음
 - 복잡한 모델에 비해 표현력이 낮음

Linear Model (선형 모델)

x(hour)	y(score)
9	90
8	80
4	40
2	20


시험성적 데이터

7시간 공부 할 경우
성적은 몇 점 일까?

Linear Model (선형 모델)

시험 성적 데이터

x(hour)	y(score)
9	90
8	80
4	40
2	20



Linear Model (선형 모델)


$$y = ax + b$$

기울기
(가중치) ↓

절편 ↓

↑ 종속변수

↑ 독립변수



Linear Model (Classification)


Linear Model - Classification

- **Logistic Regression**
(Regression 단어가 붙지만 분류용 모델)
- **Linear Support Vector Machine**

합격/불합격
여부데이터
60점 이상이면 합격


x(score)	y(pass)
90	pass
80	pass
40	fail
20	fail

합격/불합격은 실수가
아니기 때문에
좌표평면에 할당하기
애매



합격/불합격
여부데이터
60점이상이면 합격


x(score)	y(pass)
90	pass
80	pass
40	fail
20	fail



라벨 인코딩을 통해
2차원 데이터로 시각화
및 수치적 연산 가능

x(score)	y(pass)
90	1
80	1
40	0
20	0

x(score)	y(pass)
90	1
80	1
40	0
20	0




Linear Model - Logistic


- 입력과 출력이 직접적인 선형 관계가 아님
- 입력과 출력사이에 하나의 개념 생성 → 로짓(logit)
- 로짓은 입력과 선형 관계
- 특정한 계산을 통해 로짓 값을 출력인 클래스로 변환



Linear Model - Logistic



Linear Model Classification Logistic – sigmoid 함수




$$\text{sigmoid}(x) = \frac{1}{1 + e^{-x}}$$

- 로짓을 출력으로 바꾸는 수식계산에 해당
- 어떤 값이 들어와도 0~1사이 값으로 만들어버림
 - 확률처럼 해석하기 좋음

Linear Model Classification

Logistic 오차공식 – 교차엔트로피 오차(cross entropy error)



$$-\frac{1}{n} \sum y \log h + (1 - y) \log (1 - h)$$

Copyright © Gilbut, Inc. All rights reserved.

Linear Model Classification

Logistic 오차공식 – 교차엔트로피 오차(cross entropy error)

$$\theta := \theta - \alpha \cdot \nabla_{\theta} J(\theta)$$

θ : 파라미터(가중치, 편향)


α : 학습률

$J(\theta)$: 손실 함수


선형 회귀에서 MSE를 편미분하여 파라미터를 업데이트 하는 것처럼

Logistic에서는 binary cross entropy를 이용해서 파라미터를 업데이트

Linear Model Classification Support Vector Machine (SVM)




Linear Model Classification Support Vector Machine (SVM)



장단점 및 주요 매개변수(Hyperparameter)

- 선형 모델은 학습 속도가 빠르고 예측도 빠름
- 매우 큰 데이터 세트와 희소 (sparse)한 데이터 세트에서도 잘 동작
- 특성이 많을 수록 더욱 잘 동작
- 저차원(특성이 적은)데이터에서는 다른 모델이 더 좋은 경우가 많음



분류 평가 지표

Confusion_matrix

		예측 클래스(Predict Class)	
		predicted negative	predicted positive
실제 클래스(Actual Class)	negative class	TN	FP
	positive class	FN	TP

- True Negative(TN)
실제 False인 정답을 False라고 예측 (정답)
- False Positive(FP)
실제 False인 정답을 True라고 예측 (오답)
- False Negative(FN)
실제 True인 정답을 False라고 예측 (오답)
- True Positive(TP)
실제 True인 정답을 True라고 예측 (정답)

Confusion_matrix

		예측 클래스(Predict Class)	
		predicted negative	predicted positive
실제 클래스(Actual Class)	negative class	TN	FP
	positive class	FN	TP

$$\text{Accuracy} = \frac{TP + TN}{TP + TN + FP + FN}$$

정확도(Accuracy)

전체 중에 정확히 맞춘 비율

- 불균형한 데이터가 들어있을 경우 정확도로 성능을 평가하는 것은 문제가 됨

Confusion_matrix

	예측 암 X	예측 암 O
실제 암 X	95 TN	0 FP
실제 암 O	0 FN	5 TP

100명 중 암 환자는 5명
95명은 암 x, 5명은 암o 예측

100
100

$$\text{Accuracy} = \frac{\text{TP} + \text{TN}}{\text{TP} + \text{TN} + \text{FP} + \text{FN}}$$

Confusion_matrix

	예측 암 X	예측 암 O
실제 암 X	95 TN	0 FP
실제 암 O	5 FN	0 TP

100명 중 암 환자는 5명
100명 모두 암 환자 x 예측

$$\frac{95}{100}$$

$$\text{Accuracy} = \frac{\text{TP} + \text{TN}}{\text{TP} + \text{TN} + \text{FP} + \text{FN}}$$

Confusion_matrix

negative class	TN	FP
positive class	FN	TP
	predicted negative	predicted positive

재현율
(Recall)
실제 양성 중에
예측 양성 비율

$$\text{Recall} = \frac{TP}{TP + FN}$$

Confusion_matrix

	예측 암 X	예측 암 O
실제 암 X	95 TN	0 FP
실제 암 O	5 FN	0 TP

100명 중 암 환자는 5명
100명 모두 암 환자 x 예측

$$\frac{0}{5}$$

$$\text{Recall} = \frac{TP}{TP + FN}$$

Confusion_matrix

	예측 암 X	예측 암 O
실제 암 X	0	95
실제 암 O	0	5

Confusion matrix diagram showing a 2x2 grid with labels: TN (True Negative), FP (False Positive), FN (False Negative), and TP (True Positive). The values are: TN=0, FP=95, FN=0, TP=5.

100명 중 암 환자는 5명
100명 모두 암 o 예측

$$\frac{5}{5}$$

$$\text{Recall} = \frac{TP}{TP + FN}$$

Confusion_matrix

negative class	TN	FP
positive class	FN	TP
	predicted negative	predicted positive

정밀도
(Precision)
예측 양성 중에
실제 양성 비율

$$\text{Precision} = \frac{TP}{TP + FP}$$

Confusion_matrix

	예측 암 X	예측 암 O
실제 암 X	0	95
실제 암 O	0	5

100명 중 암 환자는 5명
100명 모두 암 o 예측

5

100

$$\text{Precision} = \frac{TP}{TP + FP}$$

Confusion_matrix

상황에 따른 재현율과 정밀도의 상대적인 중요도

- Recall(재현율)이 선호하는 경우
 - 실제 positive(양성)인 데이터 예측을 Negative(음성)으로 잘못 판단하게 되면 업무상 큰 영향을 줌
 - 암진단, 금융사기 판별, 도둑 판별
- Precision(정밀도)를 선호하는 경우
 - 실제 Negative(음성)인 데이터 예측을 Positive(양성)으로 잘못 판단하게 되면 업무상 큰 영향을 줌
 - 스팸메일(스팸메일 양성, 정상메일 음성)
 - 어린이 제공 영상(안전 영상 양성, 비안전 영상 음성)


Confusion_matrix

negative class	TN	FP
positive class	FN	TP
	predicted negative	predicted positive

F1 - score
정밀도와 재현율의
조화평균

$$F = 2 \frac{\text{precision} \cdot \text{recall}}{\text{precision} + \text{recall}}$$


ROC curve



$$\text{FPR} = \frac{\text{FP}}{\text{FP} + \text{TN}}$$

$$\text{TPR} = \frac{\text{TP}}{\text{TP} + \text{FN}} = \text{recall}$$

ROC curve



$$\text{FPR} = \frac{\text{FP}}{\text{FP} + \text{TN}}$$

$$\text{TPR} = \frac{\text{TP}}{\text{TP} + \text{FN}} = \text{recall}$$

THE END