



Machine Learning

Chapter01 머신러닝 개요
양재원 연구원



강사 소개



자기 소개



1. 인적사항

이름 양재원

학력

석박사 연세대학교 산업공학과 박사 수료

학사 고려대학교 바이오의공학과 졸업

연구 분야 NLP / Ontology / Computer Vision / XAI

2. 수행 연구 요약

특허 토픽모델링을 통한 기술 동향 파악과 미래 기술 예측 (NLP)

지식 그래프와 LLM을 활용한 지능형 검색 시스템 개발 (NLP, Ontology)

딥페이크 탐지 모델 개발 및 학습 데이터 생성 (Computer Vision)

배터리 제조 시 새롭게 나타나는 결함 탐지를 위한 모델 개발 (Computer Vision)

수어 인식 및 생성을 통한 양방향 번역 모델 개발 (Computer Vision, NLP, Multimodal)


설명 가능한 인공지능 모델 개발 (Explainable AI, XAI)

- Machine Learning 개념을 이해 할 수 있다.
- Machine Learning의 종류 및 과정을 알 수 있다.
- 기계학습과 관련된 기본 용어를 알 수 있다.

Artificial Intelligence

인공지능


사고나 학습등 인간이 가진
지적 능력을 컴퓨터를 통해
구현하는 기술



Machine Learning

머신러닝


컴퓨터가 스스로 학습하여
인공지능의 성능을
향상 시키는 기술 방법



Deep Learning

딥러닝

인간의 뉴런과 비슷한
인공신경망 방식으로
정보를 처리



- 데이터를 기반으로 학습을 시켜서 예측하게 만드는 기법
- 인공지능의 한 분야로 컴퓨터가 학습할 수 있도록 하는 알고리즘기술을 개발하는 분야
- 통계학, 데이터 마이닝, 컴퓨터과학이 어우러진 분야



Alan Mathison Turing
(1912.6.23 ~ 1954.6.7)

영국의 수학자, 암호학자, 논리학자


앨런 튜링


1950년 발표 논문

'기계도 생각할 수 있을까(Can Machines Think?)'

Turing Test (튜링 테스트)


기계가 인간과 비슷하게 대화가 가능하다면
기계에 지능이 있다고 인정하는 방식





Turing Test 최초 통과 유진 구스트만

Dartmouth AI Project (1956) 인공지능 용어 등장



Alan Turing (1912~1954)
Turing Test('1950):
기계(컴퓨터)가 인공지능을
갖추었는지를 판별하는 실험

암흑기
1st AI Winter

암흑기
2nd AI Winter

1950

1960

1970

1980

1990

2000

2010 ~


인간 전문가들의 지식을 하나하나
입력해 만든 규칙 기반 시스템

AI 부활
Deep Learning

- 약한인공지능(Artificial Narrow Intelligence)
 - 특정분야를 위해 제작된 인공지능
 - 체스, 퀴즈, 자율주행, 상품 추천, 번역시스템, 알파고(특정임무수행) 등
- 강한인공지능(Artificial General Intelligence)
 - 모든 방면에서 인간급의 인공지능
 - 사고, 계획, 문제해결, 추상화, 복잡한개념학습
- 초인공지능(Artificial Super Intelligence)
 - 과학기술, 사회적 능력 등 모든 영역에서 인간보다 뛰어남
 - “충분히 발달한 과학은 마법과 구분할 수 없다” -아서C. 클라크

불쾌한 골짜기

인간이 로봇에 대해 호감도가
증가하다가 어느 정도에 도달하면
갑자기 강한 거부감을 느끼는 현상



불쾌한 골짜기

인간이 로봇에 대해 호감도가 증가하다가
어느 정도에 도달하면 갑자기 강한 거부감을
느끼는 현상




지능, 윤리&도덕 관점

단순히 똑똑한 것을 넘어 서서
옳고, 그름을 판별할 수 있는
지능을 가지는 것이 인공지능
과제



지능, 윤리&도덕 관점


단순히 똑똑한 것을 넘어 서서
옳고, 그름을 판별할 수 있는
지능을 가지는 것이 인공지능
과제




자율주행차의 윤리적 딜레마

규칙 기반 전문가 시스템

“if”와 “else”로 하드 코딩된 명령을 사용하는 시스템





- 많은 상황에 대한 규칙들을 모두 만들어 낼 수 없음
- 제작한 로직이 특정 작업에만 국한되어 작업이 조금만 변경되어도 전체 시스템을 다시 만들어야 할 가능성 높음
- 규칙을 설계하려면 해당 분야에 대해서 잘 알아야 함
- 예) 자연어 처리, 스팸 메일 필터, 얼굴 인식 시스템



데이터를 이용하여 스스로 특성과 패턴을 찾아
학습하고 예측을 수행하는 것

머신러닝 종류

- ✔ 지도학습 (Supervised Learning)
- ✔ 비지도학습 (Unsupervised Learning)
- ✔ 강화학습 (Reinforcement Learning)

✓ 지도학습 (Supervised Learning)

- 데이터에 대한 Label(명시적인 답)이 주어진 상태에서 컴퓨터를 학습시키는 방법.
- 분류(Classification)와 회귀(Regression)

✔ 지도학습 (Supervised Learning) - 분류 (Classification)

- 미리 정의된 여러 클래스 레이블 중 하나를 예측하는 것 (범주형)
- 속성 값을 입력, 클래스 값을 출력으로 하는 모델
- 붓꽃(iris)의 세 품종 중 하나로 분류, 암 양성 음성 중 하나로 분류 등
- 이진 분류, 다중 분류


✔ 지도학습 (Supervised Learning) - 회귀 (Regression)

- 연속적인 숫자를 예측하는 것
- 속성 값을 입력, 연속적인 실수 값을 출력으로 하는 모델
- 어떤 사람의 교육수준, 나이, 주거지를 바탕으로 연간 소득 예측 등
- 예측 값의 미묘한 차이가 크게 중요하지 않음

✔ 지도학습 (Supervised Learning) 예시



스팸 메일 분류



집 가격 예측

✔ 비지도학습 (Unsupervised Learning)

- 데이터에 대한 Label(명시적인 답)이 없는 상태에서 컴퓨터를 학습시키는 방법
- 데이터의 숨겨진 특징, 구조, 패턴을 파악하는데 사용
- 클러스터링(Clustering), 차원축소(Dimensionality Reduction) 등

✔ 비지도학습 (Unsupervised Learning)



이미지 감색 처리



소비자 그룹 발견을
통한 마케팅

✓ 강화학습 (Reinforcement Learning)

- 지도학습과 비슷하지만 완전한 답(Label)을 제공하지 않음.
- 기계는 더 많은 보상을 얻을 수 있는 방향으로 행동을 학습.
- 주로 게임이나 로봇을 학습시키는데 많이 사용.

✔ 강화학습 (Reinforcement Learning) 예시



머신러닝 과정

1. Problem Identification(문제정의)
2. Data Collect(데이터 수집)
3. Data Preprocessing(데이터 전처리)
4. EDA(Exploratory Data Analysis)(탐색적 데이터분석)
5. Model 선택, Hyper Parameter 조정
6. Training(학습)
7. Evaluation(평가)

머신러닝 과정 1. Problem Identification(문제정의)

- 비즈니스 목적 정의모델을 어떻게 사용해 이익을 얻을까?
- 현재 솔루션의 구성 파악
- 지도 vs 비지도 vs 강화
- 분류 vs 회귀

Q. 분류? 회귀?

분류 ? 회귀 ?



다음 학기 성적을 예측하려면
어떤 특성이 필요할까?

직전 학기 성적, 알바 진행 여부, 연애,
잠자는 시간, 출석률, 학교와 집 사이 거리

머신러닝 과정 2. Data Collect(데이터 수집)

- File (CSV, XML, JSON)
- Database
- Web Crawler (뉴스, SNS, 블로그)
- IoT 센서를 통한 수집
- Survey

머신러닝 과정 3. Data Preprocessing(데이터 전처리)

- 결측치, 이상치 처리
- Feature Engineering (특성공학): Scaling (단위 변환), Encoding (범주형 -> 수치형), Binning (수치형 -> 범주형),
- Transform (새로운 속성 추출),

머신러닝 과정 4. EDA(탐색적 데이터분석)

- 기술통계, 변수간 상관관계
- 시각화: pandas, matplotlib, seaborn
- Feature Selection (사용할 특성 선택)

머신러닝 과정 5. Model 선택, Hyper Parameter 조정

- 목적에 맞는 적절한 모델 선택
- KNN, SVM, Linear Regression, Ridge, Lasso, Decision Tree, Random forest, CNN, RNN ...
- Hyper Parameter
model의 성능을 개선하기위해 사람이 직접 넣는 parameter



트레인, 테스트 데이터

X
Feature, 독립변수


Y
Label, 종속변수

Train
Data

7

Test
Data

3



머신러닝 과정 6. Model Training(학습)

- `model.fit(X_train,y_train)`
 - train 데이터와 test 데이터를 7:3 정도로 나눔
 - train 데이터의 문제와 정답으로 모델 학습
- `model.predict (X_test)`
 - test 데이터의 문제를 넣고 정답을 예측

머신러닝 과정 7. Evaluation(평가)


분류

- accuracy(정확도)
- recall(재현율)
- precision(정밀도)
- f1 score
- roc곡선의 auc

회귀

- MSE(Mean Squared Error)
- RMSE(Root Mean Squared Error)
- R^2 (R Square)

머신러닝 과정



머신러닝 모델 학습을 위한 도구

scikit-learn

- 파이썬에서 쉽게 사용할 수 있는 머신러닝 프레임워크, 라이브러리
- 회귀, 분류, 군집, 차원 축소, 특성 공학, 전처리, 교차 검증, 파이프라인 등 머신러닝에 필요한 기능을 갖추
- 학습을 위한 샘플 데이터도 제공

Model
(알고리즘)

```
knn_model=KNeighborsClassifier(n_neighbors=1)
knn_model.fit(문제 , 답)
knn_model.predict(예측값을 얻고 싶은 데이터 )
score=metrics.accuracy_score(실제답, 예측결과 )
```

KNN 분류 모델을 사용


비만도 데이터 이용 학습해 보자

	A	B	C	D
1	Gender	Height	Weight	Label
2	Male	174	96	Obesity
3	Male	189	87	Normal
4	Female	185	110	Obesity
5	Female	195	104	Overweight
6	Male	149	61	Overweight
7	Male	189	104	Overweight
8	Male	147	92	Extreme Obesity
9	Male	154	111	Extreme Obesity
10	Male	174	90	Overweight
11	Female	169	103	Obesity
12	Male	195	81	Normal
13	Female	159	80	Obesity
14	Female	192	101	Overweight
15	Male	155	51	Normal
16	Male	191	79	Normal
17	Female	153	107	Extreme Obesity
18	Female	157	110	Extreme Obesity
19	Male	140	129	Extreme Obesity
20	Male	144	145	Extreme Obesity

회귀 문제?
분류 문제?

Machine Learning

Chapter02 일반화,과대,과소,KNN
양재원 연구원



- 일반화, 과대적합, 과소적합을 이해 할 수 있다.
- KNN 알고리즘을 이해 할 수 있다.
- 하이퍼파라미터 튜닝을 할 수 있다.

일반화,과대적합,과소적합

모델의 신뢰도를 측정하고, 성능을 확인하기 위한 개념



아이에게 공이 무엇인지 알려주자

공에 대해 설명1
과대적합



과대적합



공의 종류는 다양,
축구공에 대해서만

둥글게 생겼다.
오각형이 여러 개 붙어있다.
검은색과 흰색으로 구성된다.
반짝반짝 광이 난다.

공에 대해 설명2
과소적합

과소적합

공이라는 것은..

둥글게 생겼다.



과대적합,과소적합,일반화

✔ 과대적합(Overfitting)

- train(학습) 데이터에 너무 과도하게 학습되어 train 데이터에만 잘 동작하고 test(평가) 에서는 예측 성능이 저하되는 현상

✔ 과소적합(Underfitting)

- Train 데이터를 충분히 반영하지 못해 train, test 데이터 모두에서 예측성능이 저하되는 현상 (학습을 제대로 하지 못한것)

✔ 일반화(Generalization) ← 우리의 목표!!

- Train 데이터로 학습한 모델이 test 데이터에 대해서도 정확히 예측하는 현상

과대적합(Overfitting)

어떤 고객이 보트를 살 것인가?

나이는 50살 이상

주택보유자

보유차량 수는 2대 이하

자녀 수는 2명 이상

미혼이 아닌 사람

A보트 회사의 고객 데이터

나이	보유차량수	주택보유	자녀수	혼인상태	애완견	보트구매
66	1	yes	2	사별	no	yes
52	2	yes	3	기혼	no	yes
22	0	no	0	기혼	yes	no
25	1	no	1	미혼	no	no
44	0	no	2	이혼	yes	no
39	1	yes	2	기혼	yes	no
26	1	no	2	미혼	no	no
40	3	yes	1	기혼	yes	no
53	2	yes	2	이혼	no	yes
64	2	yes	3	이혼	no	no
58	2	yes	2	기혼	yes	yes
33	1	no	1	미혼	no	no

과소적합(Underfitting)

어떤 고객이 보트를 살 것인가?

주택을 보유하고 있는 사람

보트 회사의 고객 데이터

나이	보유차량수	주택보유	자녀수	혼인상태	애완견	보트구매
66	1	yes	2	사별	no	yes
52	2	yes	3	기혼	no	yes
22	0	no	0	기혼	yes	no
25	1	no	1	미혼	no	no
44	0	no	2	이혼	yes	no
39	1	yes	2	기혼	yes	no
26	1	no	2	미혼	no	no
40	3	yes	1	기혼	yes	no
53	2	yes	2	이혼	no	yes
64	2	yes	3	이혼	no	no
58	2	yes	2	기혼	yes	yes
33	1	no	1	미혼	no	no


과대적합, 과소적합, 일반화

일반화 성능이 최대화 되는 모델을 찾는 것이 목표




- 과대적합 (Overfitting)
너무 상세하고 복잡한 모델링을 하여 훈련데이터에만 과도하게 정확히 동작하는 모델
- 과소적합 (Underfitting)
모델링을 너무 간단하게 하여 성능이 제대로 나오지 않는 모델

모델 복잡도 곡선



모델의 복잡도 해결

- 일반적으로 데이터 양이 많으면 일반화에 도움이 됨
- 주어진 훈련데이터의 다양성 보장되어야 함
- 편중된 데이터를 모으는 것 지양
- 규제(Regularization)을 통해 모델의 복잡도를 적정선으로 설정



K-Nearest Neighbors (KNN)

K-Nearest Neighbors (KNN)란?


k-최근접 이웃 알고리즘

- 유유상종의 개념과 유사
- 새로운 데이터 포인트와 가장 가까운 훈련 데이터셋의 데이터 포인트를 찾아 예측
- k 값에 따라 가까운 이웃의 수가 결정
- 분류와 회귀에 모두 사용 가능

K-Nearest Neighbors (KNN)

k-최근접 이웃 알고리즘

KNN (k=3)




	Survived
	Dead

K-Nearest Neighbors (KNN)

k-최근접 이웃 알고리즘


KNN (k=5)



K-Nearest Neighbors (KNN)

k-최근접 이웃 알고리즘


KNN ($k=1$)



K-Nearest Neighbors (KNN)

k-최근접 이웃 알고리즘


KNN ($k=11$)



K-Nearest Neighbors (KNN) 개념 정리

k-최근접 이웃 알고리즘

- k 값이 작을 수록 모델의 복잡도가 상대적으로 증가(noise 값에 민감)
새로운 데이터를 잘 예측하지 못함
- 반대로 k 값이 커질수록 모델의 복잡도가 낮아짐
제대로된 성능을 내지 못함




주요 매개변수(Hyperparameter)

scikit-learn의 경우


`KNeighborsClassifier(n_neighbors=이웃의 수)` ^{k값}

K-Nearest Neighbors (KNN) 거리 공식

k-최근접 이웃 알고리즘



$$a^2 + b^2 = c^2 \text{ (피타고라스의 정리)}$$



K-Nearest Neighbors (KNN) 거리 공식

k-최근접 이웃 알고리즘

유클리디언 거리공식 (**Euclidean Distance**)

데이터 포인트(sample) 사이 거리 값 측정 방법

$$\sqrt{(p_1 - q_1)^2 + (p_2 - q_2)^2 + \dots + (p_n - q_n)^2} = \sqrt{\sum_{i=1}^n (p_i - q_i)^2}$$

	Feature1	feature2	feature3	
재영	4	3	1	
미리	5	2	0	

K-Nearest Neighbors (KNN) 장단점 및 키워드



k-최근접 이웃 알고리즘

- n_neighbors : 이웃의 수
- 이해하기 매우 쉬운 모델, 큰 조정 없이도 나쁘지 않은 성능을 발휘하는 기초모델
- 새로운 테스트 데이터 세트가 들어오면 훈련데이터 세트와의 거리를 계산해서 훈련 데이터 세트가 크면(특성,샘플의 수) 예측이 느려짐
- 거리를 측정하기 때문에 데이터의 스케일(scale) 조정이 필요할 수 있음
- 직접적인 예측에 사용되기보다는 주로 데이터를 파악하기 위한 용도로 가볍게 사용

K-Nearest Neighbors (KNN) 실습1

iris 데이터를 이용한 KNN 분류 실습

붓꽃(iris) 데이터 셋(scikit-learn 제공)



붓꽃(iris) 데이터 셋(scikit-learn 제공)

- 150개의 데이터
- 4개의 특성과 1개의 정답(3개의 품종)로 구성

	sepal_length	sepal_width	petal_length	petal_width	species
	꽃받침 길이	꽃받침 넓이	꽃잎 길이	꽃잎 넓이	품종
1	5.1	3.5	1.4	0.2	setosa
2	4.9	3.0	1.4	0.2	
3	4.7	3.2	1.3	0.2	
...					
150	5.9	3.0	5.1	1.8	virginica

train_test_split() 함수

- 데이터 셋에서 훈련데이터와 테스트데이터로 분리하는 기능

```
from sklearn.model_selection import train_test_split
```

```
X_train, X_test, y_train, y_test = train_test_split(X, y,  
                                                    test_size = 0.3,  
                                                    random_state=0)
```

X : 특성 데이터

y : 라벨 데이터

test_size : 테스트 셋의 비율

random_state : 선택할 데이터 시드