


Machine Learning

Chapter05 Linear Regression

양재원 연구원






- 회귀 및 선형 회귀의 개념과 필요성을 이해하고 숙지한다.
- 회귀 모델의 평가지표를 이해하고 그 종류를 숙지한다.
- 경사하강법의 개념과 그 종류를 이해하고 숙지한다.



머신러닝 개략도





연속적인 실수 값을 예측하는 분야
직선의 형태를 가지는 1차식으로 연속적인
실수 값을 예측하는 모델

여러 개의 독립변수 x (특성)와 종속변수 y (예측값)의
선형 상관 관계를 모델링




회귀의 중요성 및 필요성

- 선형 회귀는 **규제가 있는 회귀 모델(Lasso, Ridge)**과 **딥 러닝 이론의 기초**
- 회귀는 **현업에서 많이 사용**되며 **활용 분야가 매우 넓음**



연봉 예측




주가 예측



회귀의 중요성 및 필요성

20대 후반 취업자수 증감 추이

분기별 25~29세 취업자수 증감, 단위: 만명(전년 동기 대비)



연합뉴스

김민지기자 = minfo@yna.co.kr
20250414


통계 자료

구글 머신러닝으로 순식간에 일기예보... 연구 성과 공개

권현주 기자 | 승인 2020.01.15 16:47 | 댓글 0



머신러닝의 중요한 장점은 이미 훈련된 모델을 고려할 때 추론이 계산 비용이 저렴하여 거의 즉각적이고 입력 데이터의 기본 고해상도로 예측할 수 있다는 점이다.



기상 예측




선형 회귀(Linear Regression)

선형 회귀(Linear Regression)

x(hour)	y(score)
9	90
8	80
4	40
2	20

시험성적 데이터

7시간 공부
시 성적은?






선형 회귀(Linear Regression)

선형 회귀(Linear Regression)

X_train	y_train
공부시간(x)	시험성적(t)
9	74
14	81
21	86
27	88
32	90
37	92






선형 회귀(Linear Regression)

선형 회귀(Linear Regression)

- 학습 데이터에는 없는 미지의 데이터에 대한 값을 예측할 때,
- 데이터의 분포를 가장 잘 표현할 수 있는 직선($y=wx+b$)을 그려서 값을 예측하는 방법





선형 모델(Linear Model - Regression)

$$y = wx + b$$

기울기 (가중치) ↓

절편 (편향) ↓

↑ 종속(응답) 변수
= 시험 성적
= 예측값

↑ 독립(입력) 변수
= 공부한 시간
= 특성값



선형 모델(Linear Model - Regression)

다중 선형 회귀 함수

$$y = w_1x_1 + w_2x_2 + w_3x_3 + \cdots + w_px_p + b$$

- w : 가중치(weight), 계수(coefficient)
- b : 편향(bias), 절편(intercept)
-
- 모델 w 파라미터 : `model.coef_`
- 모델 b 파라미터 : `model.intercept_`



회귀 모델의 성능은 어떻게 평가해야 할까?

MSE, RMSE, MAPE, R2 Score



회귀 모델 평가 지표


예측값

$$H(x) = w * x + b$$

예측값 정답값


$$\text{오차} = H(x) - y$$

↑
절대값 또는
제곱 값 사용





회귀 모델 평가 지표





평균제곱오차 (MSE : Mean Squared Error)

$$MSE = \frac{1}{m} \sum_{i=1}^m \boxed{\overset{\text{예측값}}{H(x_i)} - \overset{\text{오차}}{y_i}}^2 \underset{\text{정답값}}{}$$


평균제곱근오차 (RMSE : Root Mean Squared Error)

$$RMSE = \sqrt{\frac{1}{m} \sum_{i=1}^m (H(x_i) - y_i)^2}$$



두 데이터의 MSE 값을 계산해보자.

x(hour)	y(score)
1	1
2	2
3	3






회귀 모델 평가 지표 종류

RMSE/MSE의 단점

- 예측 대상의 크기에 영향을 받음



**삼성전자와 하이닉스의 시세예측 RMSE가 50,000이 나왔다면
두 모델의 성능은 동일할까요?**



평균절대비율오차 (MAPE : Mean Absolute Percentage Error)

- 예측값과 실제값을 뺀(오차) 후 실제값으로 나눈 값의 평균 백분율로 표현하여 RMSE의 단점을 해결!

$$MAPE = \frac{100}{m} \sum_{i=1}^m \left| \frac{y_i - H(x_i)}{y_i} \right|$$



R2 Score

$$R^2 = 1 - \frac{\text{오차의 제곱의 합}}{\text{편차의 제곱의 합}}$$

- 회귀 함수(직선)가 **평균에 비해 얼마나 그 데이터를 잘 설명**할 수 있는가에 대한 점수
- 편차 = 실제값과 **평균**과의 거리
- 오차 = 실제값과 **회귀직선**과의 거리
- 일반적으로 0에서 1사이의 값이지만 예측이 심하게 어긋날 경우 - 값이 나올 수 있음
(- 값이 나온다는 것은 회귀 직선이 평균보다 더 데이터를 잘 설명하지 못한다는 뜻)



Linear Model 장점

- 결과예측(추론) 속도가 빠르다.
- 대용량 데이터에도 충분히 활용 가능하다.
- 특성이 많은 데이터 세트라면 훌륭한 성능을 낼 수 있다.



Linear Model 단점

- 특성이 적은 저차원 데이터에서는 다른 모델의 일반화 성능이 더 좋을 수 있다. ➡ 특성확장을 하기도 한다.
- LinearRegression Model은 복잡도를 제어할 방법이 없어 과대적합 되기 쉽다.




모델 정규화(Regularization)을 통해 과대적합을 제어한다.



선형 회귀(Linear Regression)

Linear Model 단점






경사하강법(Gradient Descent Algorithm)

- 평균 제곱 오차(MSE)가 최소가 되게 하는 최적의 w , b 값을 찾는 방법론
- 기계가 스스로 학습한다는 머신, 딥러닝의 개념을 있게 한 핵심 알고리즘



Linear Model - 경사하강법

경사하강법 (Gradient Descent Algorithm)






경사하강법 (Gradient Descent Algorithm)

선형 회귀의 비용함수
= 평균제곱오차(MSE)


$$MSE = \frac{1}{m} \sum_{i=1}^m (H(x_i) - y_i)^2$$



비용함수의 기울기(경사)를 구하여 기울기가 낮은 쪽으로
계속 이동하여 값을 최적화 시키는 방법



경사하강법 (Gradient Descent Algorithm)



W값 갱신 과정




경사가 점차 감소되는 현상을 이용하므로 경사감소법!




경사하강법(Gradient Descent Algorithm)

최적의 w 값을
찾는 과정




최적의 직선을
생성하는 과정






경사하강법 (Gradient Descent Algorithm)

Learning rate가 큰 경우



Learning rate가 작은 경우




$$w := w - \overset{\text{학습률}}{\boxed{\eta}} \frac{\partial}{\partial w} MSE$$




Linear Model - 경사하강법

경사하강법 (Gradient Descent Algorithm)






Linear Model – 확률적 경사하강법



경사하강법
(Gradient Descent Algorithm)

- 전체 데이터를 이용하여 경사를 구하기 때문에 **최저점 수렴이 안정적**
- 전체 데이터를 모두 한 번에 처리하기 때문에 **속도가 느리고 메모리가 많이 필요**




확률적 경사하강법
(Stochastic Gradient Descent)

- 전체 데이터 중 랜덤하게 선택된 **하나의 데이터**를 이용하여 경사하강법을 진행
- 적은 데이터로 학습할 수 있고 **최적화 속도가 빠름**
- 하나의 데이터를 이용하기 때문에 기울기의 방향이 크게 바뀌고(오차율 $\uparrow$) **최저점 안착이 비교적 힘들**



확률적 경사하강법(Stochastic Gradient Descent)

- 큰 데이터셋에서 일반 경사하강법의 느린 단점을 보완하기 위한 방식
- 전체 데이터가 아닌 **일부 데이터**만으로 w, b 값을 업데이트
 - 따라서 항상 좋은 방향으로만 업데이트가 일어나지는 않음
 - 일부 데이터로 판단하기 때문에 속도가 빠름(데이터 수가 많을 때 유리)



규 제(Regularization)


L1 규제(Lasso), L2 규제(Ridge)



- 규제(정규화)의 개념과 필요성을 이해하고 숙지한다.
- 규제를 갖는 선형회귀 모델의 종류를 이해하고 숙지한다.




머신러닝 모델 개략도





선형 회귀 수업 흐름도






규제(Regularization)란?

선형 회귀 모델에서 **과대적합**의 위험을
감소시키기 위해 **w값**의 비중을 줄이는 것



선형 회귀(Linear Regression)



선형회귀 모델은 **학습 데이터를 전부 반영**하여 하나의 직선 방정식을 만들게 됨 → 학습 데이터에 과대적합 되는 것을 방지할 수 있는 방법이 없음



모델 정규화

- w (회귀 계수)값이 크다 = 입력에 따른 예측 결과가 크게 바뀜 → 새로운 데이터가 들어오면 제대로 예측하지 못할 수 있음 = 과대적합의 위험이 높음
- w 값을 적절히 낮게 조절하여 과대적합의 위험을 줄이는 것이 규제의 핵심
- L1 규제 : Lasso
w의 모든 원소에 똑같은 힘으로 규제를 적용하는 방법. 특정 계수들은 0이 됨.
특성선택(Feature Selection)이 자동으로 이루어진다.
- L2 규제 : Ridge
w의 모든 원소에 골고루 규제를 적용하여 0에 가깝게 만든다.



규제 모델의 비용함수(Cost function)

• L1 규제 : Lasso

비용함수

$$J(\theta)$$

규제의 강도(alpha)

$$\alpha \sum_{i=1}^n |\theta_i|$$

L1규제 항

• L2 규제 : Ridge

$$J(\theta) = \text{MSE}(\theta) + \alpha \frac{1}{2} \sum_{i=1}^n \theta_i^2$$

L2규제 항

• 선형회귀

$$J(\theta) = \text{MSE}(\theta)$$

구 분	라쏘(Lasso)	릿지(Ridge)	엘라스틱넷(ElasticNet)
적용 규제	L1	L2	L1+L2
특 징	- 중요 하지 않은 변수는 제외 - 특성 간 상관관계가 상대적으로 낮은 경우 사용	- 모든 변수에 같은 비율로 규제를 적용 - 특성 간 상관관계가 상대적으로 높은 경우 사용	- L1규제로 변수를 줄이고 L2규제로 남은 변수들의 영향도를 줄임 - 특성 수가 데이터 수 보다 많을 때 사용



주요 매개변수(Hyperparameter)

scikit-learn의 경우

Ridge(alpha)

Lasso(alpha)


- 규제의 강도 : alpha

alpha값이 **커지면** → 규제의 효과가 커짐(**과대적합 감소, 오차 증가**)

alpha값이 **작아지면** → 규제의 효과가 작아짐(**과대적합 증가, 오차 감소**)
(alpha값이 0이 되면 선형회귀와 같음)



선형 회귀 - 모델 정규화(Model Regularization)





Lasso, Ridge 모델을 이용해 보스턴 집 값 데이터를 활용하여
주택 가격을 예측해 보자



Linear Model – 보스턴 주택 값 예측 실습

feature_names

- CRIM : 지역별 범죄 발생률
- ZN : 25,000평방 피트를 초과하는 거주 지역의 비율
- INDUS : 비 상업 지역 넓이 비율
- CHAS : 찰스강에 대한 더미 변수(강의 경계에 위치한 경우는1, 아니면 0)
- NOX : 일산화질소 농도
- RM : 거주할 수 있는 방 개수
- AGE : 1940년 이전에 건축된 소유 주택의 비율
- DIS : 5개 주요 고용센터까지의 가중 거리
- RAD : 고속도로 접근 용이도
- TAX : 10,000달러 당 재산세율
- PTRATIO : 지역의 교사와 학생 수 비율
- B : 지역의 흑인 거주 비율
- LSTAT : 하위 계층의 비율

심화 학습

회귀를 더 깊이 — 다항회귀·규제 경로·잔차 분석·경사하강

심화 학습

회귀를 더 깊이 — 다항회귀·규제 경로·잔차 분석·경사하강

심화 학습에서 다룰 4가지

기본 실습을 마친 뒤 진행합니다

이미 배운 것

- 선형 회귀 = 데이터를 잘 지나는 직선
- 평가지표 MSE · RMSE · R^2
- 경사하강법으로 최적을 찾는다
- 규제(L1/L2)로 과대적합 방지

오늘 더 깊이

- ① 직선이 아닌 곡선을 그리려면
- ② 모델이 '어디서' 틀리는지 진단


① 다항 회귀 — 직선으로 안 되면 곡선으로

모델이 아니라 특성을 늘린다


모델을 바꾸는 것이 아니라 특성을 늘린다 — x 하나에 x^2 , x^3 을 추가하면 여전히 '선형' 모델로 곡선을 그릴 수 있다.

차수를 올릴수록: 과소적합 → 적절 → 과대적합


차수=1 테스트 R^2 = -0.55




차수=3 테스트 R^2 = 0.28



차수=10 테스트 R^2 = 0.35



차수=20 테스트 R^2 = 0.00



② Ridge vs Lasso — 그래서 무엇이 다른가



특성 선택 여부가 결정적 차이

	Ridge (L2)	Lasso (L1)	ElasticNet
계수 처리	0에 가까워짐	정확히 0이 됨	둘을 섞음
특성 선택	안 됨	자동으로 됨	됨
언제 쓰나	특성이 다 쓸모 있을 때	불필요한 특성이 많을 때	중간이 필요할 때

alpha가 커지면 규제가 강해져 과대적합 ↓ 하지만 지나치면 과소적합 — 적정값은 교차검증(RidgeCV·LassoCV)으로

③ 잔차 분석 — R^2 만으로 알 수 없는 것

모델이 '어디서' 틀리는지 진단한다



잔차 = 실제값 - 예측값. 0 주변에 무작위로 흩어져야 건강한 모델 — 패턴이 보이면 모델이 무언가 놓치고 있다는 신호

③ 잔차에서 읽는 신호

이런 패턴이 보이면 이렇게 대응한다

곡선 패턴이 보인다

선형 모델이 부적절
→ 다항 특성이나 비선형 모델

부채꼴로 퍼진다

분산이 일정하지 않음
→ 타깃 로그 변환 검토

한쪽으로 치우친다

분포가 비대칭
→ 변환하거나 이상치 확인

추가로: 가장 크게 틀린 샘플 몇 개를 직접 들여다보는 습관 — 데이터 오류나 특수 케이스를 발견하게 된다

심화 정리 — 기억할 것

이제 노트북으로 직접 확인합니다

핵심 정리

- 다항 특성으로 곡선도 학습 가능
- 차수가 곧 복잡도 (과대적합 주의)
- Ridge는 줄이고, Lasso는 0으로 만든다
- 잔차 플롯으로 모델을 진단한다
- 학습률이 경사하강의 핵심 손잡이

이제 실습으로

- 심화① 다항 회귀·과대적합
- 심화② 잔차 분석·변환